R言語で何ができるか

本実習の目的

- 医療データ科学（コア）の講義で学んだ医療データ科学の考え方を
  実際に実践すること

  基本的な実践として以下の内容をRを用いてできるようになることを目指す
- データの要約、図示
- 統計的推測、仮説検定
- 診断・予後解析研究における診断法の性能評価

実践例1: データの要約

- 医学研究では解析対象がどのような集団であったかを示すため
  解析集団に含まれる特徴量（因子、変数）の要約統計量を示すことが一般的

Rでの実行コード

```
library(mlbench)
data(PimaIndiansDiabetes2)

library(table1)
table1(~pregnant+pressure+insulin+mass+age|diabetes,data=PimaIndiansDiabetes2)
```

出力

	neg (N=500)	pos (N=268)	Overall (N=768)
pregnant			
Mean (SD)	3.30 (3.02)	4.87 (3.74)	3.85 (3.37)
Median [Min, Max]	2.00 [0, 13.0]	4.00 [0, 17.0]	3.00 [0, 17.0]
pressure			
Mean (SD)	70.9 (12.2)	75.3 (12.3)	72.4 (12.4)
Median [Min, Max]	70.0 [24.0, 122]	74.5 [30.0, 114]	72.0 [24.0, 122]
Missing	19 (3.8%)	16 (6.0%)	35 (4.6%)
insulin			
Mean (SD)	130 (102)	207 (133)	156 (119)
Median [Min, Max]	103 [15.0, 744]	170 [14.0, 846]	125 [14.0, 846]
Missing	236 (47.2%)	138 (51.5%)	374 (48.7%)
mass			
Mean (SD)	30.9 (6.56)	35.4 (6.61)	32.5 (6.92)
Median [Min, Max]	30.1 [18.2, 57.3]	34.3 [22.9, 67.1]	32.3 [18.2, 67.1]
Missing	9 (1.8%)	2 (0.7%)	11 (1.4%)
age			
Mean (SD)	31.2 (11.7)	37.1 (11.0)	33.2 (11.8)
Median [Min, Max]	27.0 [21.0, 81.0]	36.0 [21.0, 70.0]	29.0 [21.0, 81.0]

実践例2: データの図示

- データ解析においてはデータの特徴を視覚的に確認することが重要

```
data("anorexia_df")
ggplot(anorexia_df, aes(x = Prewt, y = Postwt, color =
                        Treat, shape = Treat)) +
  geom_point(size = 2) +
  labs(
    title = "Anorexia: Post vs Pre Weight by Group",
    x = "Pre-treatment Weight (kg)",
    y = "Post-treatment Weight (kg)") +
  theme_classic(base_size=18) +
  theme(plot.title = element_text(hjust=0.5))
```

出力

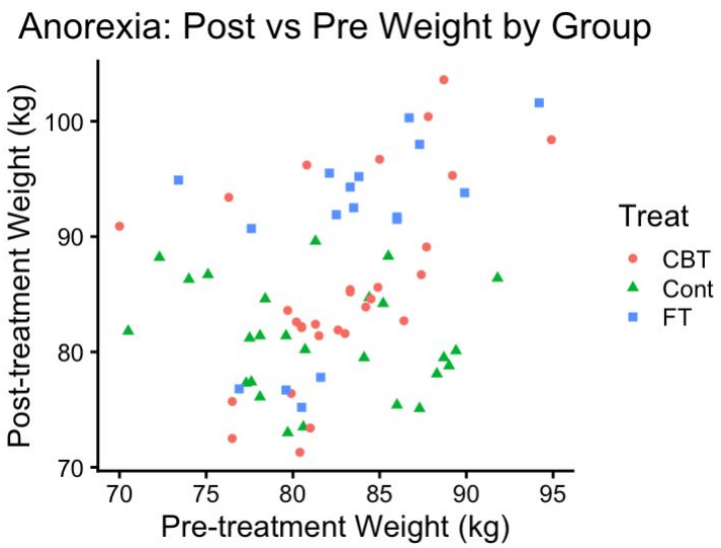

実践例3: 診断法の性能評価

- 膵がんの診断に用いられる二つの腫瘍マーカーの性能比較
  - ROC曲線: 診断の性能を包括的に示す曲線
    (異なる閾値での感度、特異度を示す)

```r
library(pROC)
library(ggplot2)
df <- read.csv("tumor_marker.csv")
roc1 <- roc(df$cancer, df$CA19.9)
roc2 <- roc(df$cancer, df$CA125)
roclist <- list(roc1,roc2)
names(roclist) <- c("CA19-9","CA125")
ggroc(roclist,legacy.axes = TRUE)+
  geom_abline(intercept=0, slope=1,col="grey")+
  theme_bw(base_size = 15)
```
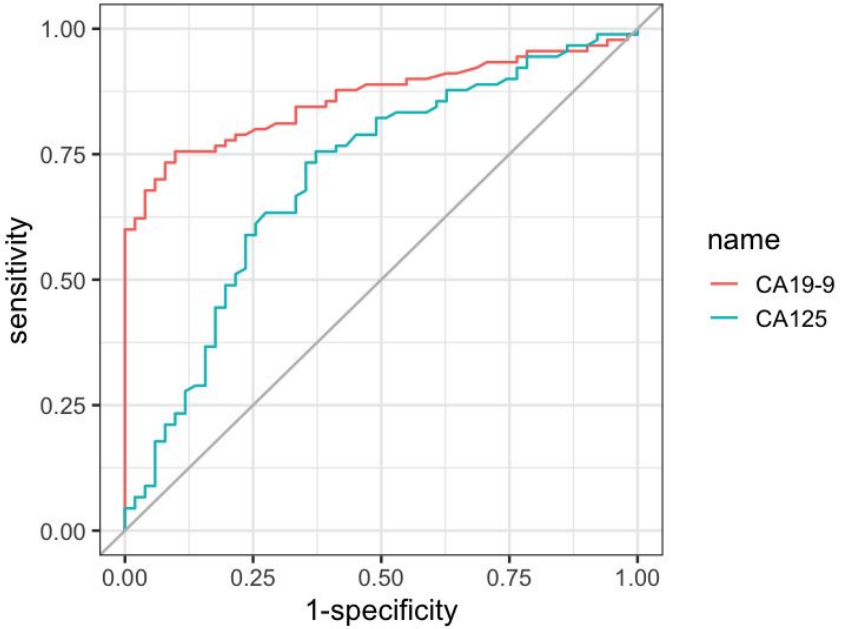
出力