

記述統計と集計

医療データ科学実習

(Practice of Biomedical Data Science)

第6回 2026年5月26日

医療データ科学

matsui.kota.8k@kyoto-u.ac.jp

臨床統計学

emoto.ryo.5m@kyoto-u.ac.jp

Slidoで質疑応答に参加しよう

医療データ科学実習第2回

Q&A

11 Polls

医療データ科学実習第2回
2025/04/15~2025/04/22
#2974 065

ライブインタラクシ...

Slido を切り替え

ダークモード

Slido について

Slido を無料で試す

質問を入力

人気 最近

質問投稿部分

1 個の質問

匿名
6 日前

テスト質問です

Moderator
6 日前

テスト質問了解です

0

人の質問に投票できる
人気の質問は上位に表示される

- 匿名で質疑応答に参加できるプラットフォーム
- スマホからでも簡単に利用できます
- 講義後1週間解放しておくので自由に質問やコメントを投稿してください

主催者としてログイン -
プレゼンテーション モード
許可可能な使用 - Slido のプライバシー
Cookie の設定
© 2012-2025 Slido - 67.29.3

slido

参加

URL: <https://app.sli.do/event/asPyC5mB2MgGfP29pvJtn2>



Chap1. 連続変数の要約統計量

- 分布の位置を表す要約指標
- 分布の広がりを表す要約指標
- 2変数の要約指標
- 層別の要約統計量の計算

使用データセット: smoking_tbl_df

英国の健康調査に基づく、喫煙に関するデータ

- 対象: イギリスにおける成人1691名の調査データ
- 変数一覧:
 - gender: 性別 (male, female)
 - age: 年齢 (整数)
 - marital_status: 婚姻状況 (single, married など)
 - highest_qualification: 最終学歴 / nationality: 国籍
 - ethnicity: 民族的背景 / gross_income: 所得水準
 - region: 地域 / smoke: 喫煙の有無 (yes, no)
 - amt_weekends: 週末の喫煙本数 (整数)
 - amt_weekdays: 平日の喫煙本数 (整数)
 - type: 喫煙者における喫煙スタイル

```
> library(MedDataSets)
> data("smoking_tbl_df")
```

分布の位置を表す指標

- `mean()`: 平均

$$\bar{x} = (x_1 + x_2 + \cdots + x_n)/n$$

- `median()`: 中央値

※欠損値(NA)がある場合は`na.rm = TRUE`を指定

```
> sum(smoking_tbl_df$age)/length(smoking_tbl_df$age)
[1] 49.83619
> mean(smoking_tbl_df$age)
[1] 49.83619
> median(smoking_tbl_df$age)
[1] 48
>
> # 欠損値がある場合、na.rmの指定が必要
> mean(smoking_tbl_df$amt_weekends)
[1] NA
> mean(smoking_tbl_df$amt_weekends, na.rm = TRUE)
[1] 16.41093
```

分布の拡がりの指標1

- `min()`, `max()`: 最小値, 最大値
- `range()`: 範囲
- `quantile()`: 分位点

四分位点を出力(default), `prob`に指定した確率に対応する分位点を出力

```
> min(smoking_tbl_df$age)
[1] 16
> max(smoking_tbl_df$age)
[1] 97
> range(smoking_tbl_df$age)
[1] 16 97
> quantile(smoking_tbl_df$age)
 0%  25%  50%  75% 100%
16.0 34.0 48.0 65.5 97.0
> quantile(smoking_tbl_df$age, prob=seq(0,1,0.1))
 0%  10%  20%  30%  40%  50%  60%  70%  80%  90% 100%
 16   26   32   37   42   48   55   62   69   76   97
```

分布の広がり指標2

- `var()`: 分散
- `sd()`: 標準偏差

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$
$$\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

演習 `smoking_tbl_df$age`の分散・標準偏差を`var()`、`sd()`で計算し、定義式から計算した結果と一致することを確認してください

```
> var(smoking_tbl_df$age)
[1] 351.0696
> sum((smoking_tbl_df$age-mean(smoking_tbl_df$age))^2)/(length(smoking_tbl_df$age)-1)
[1] 351.0696

> sd(smoking_tbl_df$age)
[1] 18.73685
> sqrt(var(smoking_tbl_df$age))
[1] 18.73685
```

summary()関数による要約統計量の表示

- `summary()` 関数: データの要約統計量をまとめて表示する関数
 - データフレーム、ベクトルの双方を入力可能

```
> summary(smoking_tbl_df)
  gender      age      marital_status      highest_qualification      nationality
Female:965  Min.   :16.00  Divorced  :161  No Qualification  :586  English :833
Male   :726  1st Qu.:34.00  Married   :812  GCSE/O Level      :308  British :538
          Median :48.00  Separated: 68  Degree             :262  Scottish:142
          Mean   :49.84  Single    :427  Other/Sub Degree   :127  Other   : 71
          3rd Qu.:65.50  Widowed   :223  Higher/Sub Degree :125  Welsh   : 66
          Max.   :97.00              A Levels      :105  Irish   : 23
                                   (Other)       :178  (Other) : 18
```

略

ピアソンの相関係数

- `cor()`: 相関係数(直線関係の強さ)を算出
 - `use`の指定で欠損値に対する対処を指定
 - `method`で相関係数の種類を指定可能(Kendall, Spearman)

```
> cor(smoking_tbl_df$age, smoking_tbl_df$amt_weekends, use =  
"pairwise.complete.obs")  
[1] 0.05864156  
>  
> cor(smoking_tbl_df$age, smoking_tbl_df$amt_weekends, use =  
"pairwise.complete.obs", method = "kendall")  
[1] 0.07509037  
>  
> cor(smoking_tbl_df$age, smoking_tbl_df$amt_weekends, use =  
"pairwise.complete.obs", method = "spearman")  
[1] 0.1050787
```

層別の要約統計量

層(stratum)とは、カテゴリ変数に基づいて、互いに重ならないグループに分割したもののデータを層に分け、層ごとに要約統計量を計算

いくつかの方法で実行可能

x: 計算したい変数

y: 層を表す変数

f: 統計量を計算する関数

- `tapply(x, y, f)`
リストで出力
- `aggregate(x ~ y, f)`
データフレームで出力
- `by(x, y, f)`
独自の形式で出力

```
> tapply(smoking_tbl_df$age, smoking_tbl_df$smoke, summary)
$No
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 16.0   37.0   52.0   52.2   69.0   97.0

$Yes
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
16.00   30.00   40.00  42.71   54.00   93.00

> aggregate(age ~ smoke, data = smoking_tbl_df, summary)
  smoke age.Min. age.1st Qu. age.Median age.Mean age.3rd Qu. age.Max.
1   No 16.00000   37.00000   52.00000 52.19685  69.00000 97.00000
2   Yes 16.00000   30.00000   40.00000 42.71496  54.00000 93.00000
> by(smoking_tbl_df$age, smoking_tbl_df$smoke, summary)
smoking_tbl_df$smoke: No
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 16.0   37.0   52.0   52.2   69.0   97.0

-----
smoking_tbl_df$smoke: Yes
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
16.00   30.00   40.00  42.71   54.00   93.00
```

演習問題1

喫煙に関する変数について、以下を計算してください

1. gender ごとに週末の喫煙本数 (amt_weekends) の平均と標準偏差を計算
2. 年齢を40歳未満, 40-64歳, 65歳以上に階級分けし、各層ごとに平日の喫煙本数 (amt_weekdays) の中央値を計算

演習問題1: Rコード例

```
> aggregate(amt_weekends ~ gender, data = smoking_tbl_df, mean)
  gender amt_weekends
1 Female      15.00427
2   Male      18.17112
>
> aggregate(amt_weekends ~ gender, data = smoking_tbl_df, sd)
  gender amt_weekends
1 Female      8.596085
2   Male     11.082905
>
> smoking_tbl_df$age_cat <- cut(smoking_tbl_df$age, breaks = c(0, 40, 65, Inf))
> aggregate(amt_weekends ~ age_cat, data = smoking_tbl_df, mean)
  age_cat amt_weekends
1  (0,40]      15.15023
2 (40,65]      18.65605
3 (65,Inf]      14.76471
```

Chap2. カテゴリカル変数の 要約統計量

- 最頻値
- 分割表の要約指標

最頻値

- Rには最頻値を求める組込み関数は存在しない
(mode()はデータの型に関する関数)
- table() 関数とwhich.max() 関数などを用いて手計算は可能

```
> table_age <- table(smoking_tbl_df$age)
> which.max(table_age)
40
25
```

(復習)分割表:複数の名義・順序変数の関係

二つの名義・順序変数の分割表

変数 A	変数 B			合計
	水準 B_1	...	水準 B_j	
水準 A_1	A_1 & B_1 の 頻度 (%)	...	A_1 & B_j の 頻度 (%)	A_1 の 頻度 (%)
⋮	⋮	同時分布	⋮	⋮
水準 A_k	A_k & B_1 の 頻度 (%)	...	A_k & B_j の 頻度 (%)	A_k の 頻度 (%)
合計	B_1 の 頻度 (%)	...	B_j の 頻度 (%)	全体の 合計

周辺分布 (marginal distribution)

(注: 同時分布の割合 (%) の分母は三通り. どれを報告するかはケースバイケースで判断)

(復習)2×2分割表と指標

2値のアウトカム変数(例: 生存/死亡)と2値のカテゴリ変数(例: 治療あり/なし)の関係が以下のような分割表で表されるとする

頻度の表

	死亡	生存	合計
治療なし	a	b	$a + b$
治療あり	c	d	$c + d$
合計	$a + c$	$b + d$	n

確率の表

	死亡	生存	合計
治療なし	p_0	$1 - p_0$	1
治療あり	p_1	$1 - p_1$	1

- リスク差 (Risk Difference, RD): $RD = p_1 - p_0$
- リスク比 (Risk Ratio, RR): $RR = p_1 / p_0$
- オッズ比 (Odds Ratio, OR): $OR = (p_1 / (1 - p_1)) / (p_0 / (1 - p_0))$
- Number Needed to Treat (NNT): $NNT = 1 / (p_0 - p_1)$

演習問題2:pharmacoSmoking データの解析

asaur パッケージの pharmacoSmoking データを用いて解析を行います

このデータは禁煙治療に関するRCTのデータで

今回の解析では禁煙失敗かどうかをアウトカムとします

1. asaur パッケージのインストール、読み込み、pharmacoSmokingの読み込みを行ってください
2. relapseとgrpの分割表を作成してください
3. relapse = 1 (禁煙失敗)をイベントとして扱い、介入群(grp="combination")と対照群(grp="patchOnly")のイベント発生割合 p_1 , p_0 を計算してください
4. RD, RR, OR, NNTを算出してください

演習問題2 Rコード例

```
> tb <- table(pharmacoSmoking$grp, pharmacoSmoking$relapse)
```

```
> tb
```

```
      0    1
combination 24 37
patchOnly   12 52
```

```
> ptb <- prop.table(tb, margin=1)
```

```
> ptb
```

```
      0          1
combination 0.3934426 0.6065574
patchOnly   0.1875000 0.8125000
```

```
> p0 <- ptb[2,2]
```

```
> p1 <- ptb[1,2]
```

```
> print(c(p0 = p0, p1 = p1))
```

```
      p0      p1
0.8125000 0.6065574
```

順序に注意

演習問題2 Rコード例

```
> RD <- p1 - p0
> RR <- p1 / p0
> OR <- (p1 / (1 - p1)) / (p0 / (1 - p0))
> NNT <- 1 / (p0 - p1)
>
> print(c(RD=RD,RR=RR,OR=OR,NNT=NNT))
              RD              RR              OR              NNT
-0.2059426    0.7465322    0.3557692    4.8557214
```

- RD: combination群は禁煙失敗リスクが20.6ポイント低い
- RR: combination群の失敗リスクは対照群の約75%
- OR: combination群の失敗オッズは対照群の約36%
- NNT: 約 5人に治療を行うことで、1人の禁煙失敗を防げる

Chap3. 外部パッケージを使った 要約統計量の算出

- `dplyr` と `janitor` を使ったデータ操作・集計, クロス集計や頻度表の作成
- 組み込み関数を用いた集計と外部パッケージを用いた集計の違い

dplyr と janitor によるデータの集計

dplyr データ操作・集計の基本ツール

janitor クロス集計や頻度表をきれいに出力してくれるツール

大きな特徴: Base Rの方法に比べて追加の処理なく綺麗に集計を表示できる

演習: RStudioで下記のコードを実行してインストール・インポートしてみよう

- コンソールで以下を実行

```
install.packages("dplyr", repos="https://cloud.r-project.org")  
install.packages("janitor", repos="https://cloud.r-project.org")
```

- インストールが完了したら `library(dplyr)` , `library(janitor)` でインポート

dplyr と janitor の標準的な使い方

- Rの組み込みデータセット `iris` を使って標準的な使い方を見てみよう
 - `iris` は初めからRに含まれているので `print(iris)` で内容が確認できる

```
print(iris)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa
11	5.4	3.7	1.5	0.2	setosa

がく片の長さ, 幅

花弁の長さ, 幅

種類



[画像の出典 \(R Pubs\)](#)

dplyr と janitor の標準的な使い方

- 単純な集計その4: 要約統計量の計算

例 iris データの Sepal.Length 列の

- 平均
- 中央値
- 分散
- 標準偏差
- 最大値, 最小値

を計算する

集計の目的:

iris データセットを使い、「がく片の長さ (Sepal.Length)」という連続変数の要約統計量を計算する

dplyr と janitor の標準的な使い方

- 単純な集計その4: 要約統計量の計算

例 iris データの Sepal.Length 列の

- 平均
 - 中央値
 - 分散
 - 標準偏差
 - 最大値, 最小値
- を計算する

サンプルコード

```
iris %>%  
  summarise(  
    mean = mean(Sepal.Length),  
    median = median(Sepal.Length),  
    sd = sd(Sepal.Length),  
    var = var(Sepal.Length),  
    min = min(Sepal.Length),  
    max = max(Sepal.Length)  
  )
```


dplyr と janitor の標準的な使い方

- 単純な集計その4: 要約統計量の計算

サンプルコード

例 iris データの Sepal.Length 列の

- 平均
 - 中央値
 - 分散
 - 標準偏差
 - 最大値, 最小値
- を計算する

```
iris %>%
```

```
summarise(
```

```
  mean = mean(Sepal.Length),  
  median = median(Sepal.Length),  
  sd = sd(Sepal.Length),  
  var = var(Sepal.Length),  
  min = min(Sepal.Length),  
  max = max(Sepal.Length)  
)
```

- データ全体から要約統計量を計算して1行1列の結果を返す関数
- 複数の統計量を同時に計算できる

dplyr と janitor の標準的な使い方

- 単純な集計その4: 要約統計量の計算

例 iris データの Sepal.Length 列の

- 平均
- 中央値
- 分散
- 標準偏差
- 最大値, 最小値

を計算する

(注) 中身の計算関数は組み込み関数なので、欠損は `na.rm=TRUE` で同様に対処できる

実行結果(演習: RStudioでコードを実行して集計を表示してみよう)

```
> iris %>%
+   summarise(
+     mean = mean(Sepal.Length),
+     median = median(Sepal.Length),
+     sd = sd(Sepal.Length),
+     var = var(Sepal.Length),
+     min = min(Sepal.Length),
+     max = max(Sepal.Length)
+   )
      mean median      sd      var min max
1 5.843333   5.8 0.8280661 0.6856935 4.3 7.9
```

dplyr と janitor の標準的な使い方

- 単純な集計その5: 層別の要約統計量の計算

例 `iris` データを `Species` で層別化し、各層ごとに `Sepal.Length` 列の要約統計量(平均・標準偏差・件数)を計算

サンプルコード

```
iris %>%  
  group_by(Species) %>%  
  summarise(  
    mean = mean(Sepal.Length),  
    sd = sd(Sepal.Length),  
    n = n()  
  )
```

dplyr と janitor の標準的な使い方

- 単純な集計その5: 層別の要約統計量の計算

例 `iris` データを `Species` で層別化し、各層ごとに `Sepal.Length` 列の要約統計量(平均・標準偏差・件数)を計算

サンプルコード

```
iris %>%  
  group_by(Species) %>%  
  summarise(  
    mean = mean(Sepal.Length),  
    sd = sd(Sepal.Length),  
    n = n()  
  )
```

- `iris` データフレームを `Species` 列で層別化
- "setosa", "versicolor", "virginica"の3グループに分かれる

dplyr と janitor の標準的な使い方

- 単純な集計その5: 層別の要約統計量の計算

例 iris データを Species で層別化し、各層ごとに Sepal.Length 列の要約統計量(平均・標準偏差・件数)を計算

実行結果(**演習**: RStudioでコードを実行して集計を表示してみよう)

```
> iris %>%  
+   group_by(Species) %>%  
+   summarise(  
+     mean = mean(Sepal.Length),  
+     sd = sd(Sepal.Length),  
+     n = n()  
+   )  
# A tibble: 3 × 4  
  Species      mean    sd     n  
  <fct>    <dbl> <dbl> <int>  
1 setosa    5.01 0.352   50  
2 versicolor 5.94 0.516   50  
3 virginica 6.59 0.636   50  
> |
```

base Rによる集計と `dplyr` / `janitor` による集計の比較

観点	base R	<code>dplyr</code> / <code>janitor</code>
記述スタイル	関数中心、やや複雑	パイプ <code>%>%</code> による直感的な構文
可読性	やや低い（ネストが多い）	高い（パイプで流れが明快）
拡張性	基本的な処理には十分	グループ集計・ラベル整形に強い
表の整形	<code>table()</code> , <code>prop.table()</code>	<code>tabyl()</code> , <code>adorn_*()</code> で柔軟に整形
出力形式	配列や表形式	データフレーム（tibble）

患者背景の表の作成

gtsummary パッケージの `tbl_summary()` 関数: 要約統計量の表を簡潔に作成

基本構文:

```
data %>% tbl_summary(by=グループ変数, include=要約したい変数名ベクトル)
```

詳細な設定:

- `label`: 表示する変数名の設定(リスト形式)
- `statistic`: 表示する統計量の設定(リスト形式)
- `missing, missing_text`: NAに対する表示方法の設定

全体行の追加は別の関数 `add_overall()` で可能

同様の目的の他のパッケージも存在(パッケージ `tableone`, `table1` など)

患者背景の表の作成

例 : [pharmacoSmoking](#)データ [[Steinberg+ 2009](#)]

- 試験デザイン:

三剤併用療法 (ニコチンパッチ + ニコチン吸入器 + bupropion) vs. ニコチンパッチ単独 の禁煙ランダム化比較試験

- 規模: 125 例 × 14 変数 (以下のように原論文のデータとは大きく異なる)

- 原論文は 127 例
- 原論文で扱われていた既往歴、Fagerström スコア、教育歴、精神疾患歴、有害事象、重症度層別などの変数は含まれない

→ 再発までの時間に絞った生存時間解析の教材用として抽出・整形されたもの

患者背景の表の作成

例 : [pharmacoSmoking](#)データ [Steinberg+ 2009]

サンプルサイズ, 共変量ともに公開データに
含まれないものがあるため, → の Table 1
を完全に再現するのは無理

今回は公開データのみから部分的な再現を試
みる

年齢

性別

人種

教育歴

雇用状況

既往歴

Table 1. Baseline Demographic, Medical, and Tobacco Use Characteristics, by Treatment Group			
Characteristic	Total (n = 1277)	Combination Group (n = 63)	Patch-Alone Group (n = 64)
Age, n (%)			
<35 y	16 (12.6)	7 (11.1)	9 (14.1)
35–49 y	52 (40.9)	26 (41.3)	26 (40.6)
50–64 y	48 (37.8)	24 (38.1)	24 (37.5)
≥65 y	11 (8.7)	6 (9.5)	5 (7.8)
Sex, n (%)			
Male	45 (35.4)	23 (36.5)	22 (34.4)
Female	82 (64.6)	40 (63.5)	42 (65.6)
Race, n (%)			
Black or non-Hispanic	40 (31.5)	17 (27.0)	23 (35.9)
Hispanic	8 (6.3)	4 (6.3)	4 (6.3)
White or non-Hispanic	77 (60.6)	41 (65.1)	36 (56.3)
Other	2 (1.6)	1 (1.6)	1 (1.6)
Education, n (%)			
High school graduate or less	51 (40.2)	27 (42.9)	24 (37.5)
Some college	52 (40.9)	25 (39.7)	27 (42.2)
College graduate or more	24 (18.9)	11 (17.5)	13 (20.3)
Employment, n (%)			
Full-time	74 (58.3)	36 (57.1)	38 (59.4)
Part-time	14 (11.0)	7 (11.1)	7 (10.9)
Other	38 (29.9)	20 (31.7)	18 (28.1)
Medical history, n (%)			
Any cancer	17 (13.4)	8 (12.7)	9 (14.1)
Abnormal Papanicolaou smear*	20 (24.4)	10 (23.8)	10 (25.0)
Cardiovascular disease			
Heart disease	18 (14.2)	7 (11.1)	11 (17.2)
Stroke	7 (5.5)	3 (4.8)	4 (6.3)
Vascular disease	9 (7.1)	4 (6.3)	5 (7.8)
Chronic obstructive pulmonary disease	31 (24.4)	17 (27.0)	14 (21.9)
Cardiovascular disease risk factors			
Diabetes	20 (15.7)	9 (14.3)	11 (17.2)
Hyperlipidemia	55 (43.3)	24 (38.1)	31 (48.4)
Hypertension	52 (40.9)	28 (44.4)	24 (37.5)
Psychological or psychiatric condition			
Depression	46 (36.2)	23 (36.5)	23 (35.9)
Anxiety	33 (26.0)	14 (22.2)	19 (29.7)
Alcohol abuse	27 (21.3)	13 (20.6)	14 (21.9)
Substance abuse	14 (11.0)	9 (14.3)	5 (7.8)
Tobacco use, n (%)			
<20 cigarettes/d	44 (34.6)	21 (33.3)	23 (35.9)
≥20 cigarettes/d	83 (65.4)	42 (66.7)	41 (64.1)
Mean Fagerström test score for nicotine dependence (SD)†			
	5.20 (2.08)	5.16 (1.91)	5.23 (2.25)
Mean scores on tobacco belief scales (SD)‡			
Smoking negatively affects health	7.8 (2.4)	7.7 (2.5)	7.9 (2.3)
Quitting will improve health	9.3 (1.6)	9.4 (1.5)	9.3 (1.6)
Importance of quitting	9.4 (1.2)	9.3 (1.3)	9.4 (1.1)
Confidence in quitting	6.9 (2.3)	6.9 (2.5)	6.9 (2.2)
Readiness to quit	8.4 (1.9)	8.1 (2.0)	8.7 (1.7)

* Percentage relative to total female patients.

† The Fagerström test for nicotine dependence is a validated 6-item instrument to measure the level of dependence to nicotine. The total score range is 0 to 10, with ≥6 indicating high dependence.

‡ Belief scales were Likert scales (0 = no effect; 10 = extreme effect).

元論文の Table 1

患者背景の表の作成

例 : [pharmacoSmoking](#) データ [[Steinberg+ 2009](#)]

変数名	内容	データ型
id	患者ID	int
ttr	再発までの日数	int
relapse	再発フラグ	int
grp	割付群	factor
age	年齢	int
gender	性別	factor
race	人種	factor
employment	就労状況	factor

変数名	内容	データ型
yearsSmoking	喫煙年数	int
levelSmoking	喫煙量	factor
ageGroup2	年齢2区分	factor
ageGroup4	年齢4区分	factor
priorAttempts	過去の禁煙試行回数	int
longestNoSmoke	過去最長禁煙期間(日)	int

tbl_summary() の使用例: 喫煙データ

pharmacoSmokingデータの患者背景の表のコード例1

- 年齢、性別、人種、雇用状況、喫煙期間を要約

```
install.packages("gtsummary")
library(gtsummary)

pharmacoSmoking %>%
  tbl_summary(
    by = grp,
    include = c(age, gender, race,
employment, yearsSmoking)
  )
```

出力例1

Characteristic	combination N = 61 [†]	patchOnly N = 64 [†]
age	49 (43, 57)	49 (40, 56)
gender		
Female	39 (64%)	42 (66%)
Male	22 (36%)	22 (34%)
race		
black	15 (25%)	23 (36%)
hispanic	4 (6.6%)	4 (6.3%)
other	1 (1.6%)	1 (1.6%)
white	41 (67%)	36 (56%)
employment		
ft	34 (56%)	38 (59%)
other	20 (33%)	19 (30%)
pt	7 (11%)	7 (11%)
yearsSmoking	33 (23, 39)	30 (22, 37)
[†] Median (Q1, Q3); n (%)		

tbl_summary() のコード例2

カテゴリ名の設定、統計量の設定、全体列の追加を追加

```
tbl1 <- pharmacoSmoking %>%  
  mutate(race = factor(race, levels = c("white", "black", "hispanic", "other"), labels = c("White", "Black",  
"Hispanic", "Other")),  
         employment = factor(employment, levels = c("ft", "pt", "other"), labels = c("Full-time",  
"Part-time", "Other"))) %>%  
  tbl_summary(  
    by = grp,  
    include = c(age, gender, race, employment, yearsSmoking),  
    label = list(  
      age = "Age, years",  
      gender = "Gender",  
      race = "Race",  
      employment = "Employment status",  
      yearsSmoking = "Smoking duration, years"  
    ),  
    statistic = list(  
      all_continuous() ~ "{median} [{p25}, {p75}]",  
      all_categorical() ~ "{n} ({p}%)",  
    ),  
  ) %>%  
  add_overall(last = TRUE)  
print(tbl1)
```

カテゴリの名前、表示順を変更

行のカテゴリの表示をそれぞれ設定
(単位があるものは追加)

統計量と表示方法の指定
中央値 [四分位点]の形式に変更

全体行を右側に追加

出力例2:喫煙の有無による患者背景

Characteristic	combination N = 61 [†]	patchOnly N = 64 [†]	Overall N = 125 [†]
Age, years	49 [43, 57]	49 [40, 56]	49 [41, 56]
Gender			
Female	39 (64%)	42 (66%)	81 (65%)
Male	22 (36%)	22 (34%)	44 (35%)
Race			
White	41 (67%)	36 (56%)	77 (62%)
Black	15 (25%)	23 (36%)	38 (30%)
Hispanic	4 (6.6%)	4 (6.3%)	8 (6.4%)
Other	1 (1.6%)	1 (1.6%)	2 (1.6%)
Employment status			
Full-time	34 (56%)	38 (59%)	72 (58%)
Part-time	7 (11%)	7 (11%)	14 (11%)
Other	20 (33%)	19 (30%)	39 (31%)
Smoking duration, years	33 [23, 39]	30 [22, 37]	30 [22, 39]
[†] Median [Q1, Q3]; n (%)			

(参考) `tbl_summary()` のコード例3

パッケージ `gt` (`gtsummary`と同時にインポートされる)による表の体裁の操作

```
tbl1 %>%
  modify_footnote(everything() ~ NA) %>%
  as_gt() %>%
  gt::tbl_style(
    style = gt::cell_text(weight = "bold"),
    locations = gt::cells_body(
      rows = row_type == "label", columns = label
    )
  ) %>%
  gt::tbl_source_note(
    source_note = "Categorical variables are shown as n (%). Continuous variables are shown as median [Q1, Q3].\"
  ) %>%
  gt::tbl_options(
    table.border.bottom.style = "none",
    column_labels.border.top.color = "black",
    column_labels.border.bottom.color = "black",
    table_body.hlines.color = "grey",
    table_body.border.bottom.color = "black",
    table.font.names = "Arial",
    table.font.color = "black",
    table.font.size = 12
  )
```

(参考)出力例3:喫煙の有無による患者背景

Characteristic	combination N = 61	patchOnly N = 64	Overall N = 125
Age, years	49 [43, 57]	49 [40, 56]	49 [41, 56]
Gender			
Female	39 (64%)	42 (66%)	81 (65%)
Male	22 (36%)	22 (34%)	44 (35%)
Race			
White	41 (67%)	36 (56%)	77 (62%)
Black	15 (25%)	23 (36%)	38 (30%)
Hispanic	4 (6.6%)	4 (6.3%)	8 (6.4%)
Other	1 (1.6%)	1 (1.6%)	2 (1.6%)
Employment status			
Full-time	34 (56%)	38 (59%)	72 (58%)
Part-time	7 (11%)	7 (11%)	14 (11%)
Other	20 (33%)	19 (30%)	39 (31%)
Smoking duration, years	33 [23, 39]	30 [22, 37]	30 [22, 39]

Categorical variables are shown as n (%). Continuous variables are shown as median [Q1, Q3].

提出課題

pharmacoSmoking データから作成した喫煙の有無による患者背景の Table をcsvファイルに出力して提出してください

提出方法:KULMSの課題提出機能

提出期限:5/27(水)23:55