

統計的推測の実践1

統計モデルと回帰モデルの基礎

医療データ科学実習
(Practice of Biomedical Data Science)

第11回 2026年6月30日

医療データ科学

matsui.kota.8k@kyoto-u.ac.jp

臨床統計学

emoto.ryo.5m@kyoto-u.ac.jp

質問はslidoでもOK

参加

URL: <https://app.sli.do/event/vaH zr518EzaMEta8GiMWVx>



統計モデルと回帰モデルの基礎

- 統計モデル・回帰モデルとは？（午前の講義の復習）
- 線形回帰モデルによる解析
- ロジスティック回帰モデルによる解析

統計モデルと回帰モデルの基礎

- 統計モデル・回帰モデルとは？（午前の講義の復習）
- 線形回帰モデルによる解析
- ロジスティック回帰モデルによる解析

「モデル (model) 」とは？

広辞苑*によると：

- ・ 型、型式、模型、ひな形、模範、手本
- ・ 美術家が制作の対象とする人
- ・ 小説・戯曲などの題材とされた実在の人物
- ・ ファッション・モデルの略

モデルを使うための、なにかしらの目的がある

目的達成のために「興味ある対象のすべてでなく、それがもつ
特定の側面に着目し、表現したもの」といった概念といえるだろう

統計モデルとは？

- 統計モデルとは（ばらつきのある）データがどのように生成されるかを表す数学的な表現. データ解析者が指定
- 興味のある現象のデータに基づいて、その説明（帰納的推論）や予測を試みるために導入される（＝モデル導入の目的）
- データが生成される“真のメカニズム”（データの背後にある実体）を完全に捉えるものである必要はない
- 大半の統計モデルは、データの“表面的な”挙動（データの分布）を捉えることに専念

統計モデルは正しいのか？

All models are wrong, but some are useful.

Box GEP & Draper NR, 1987

- ほとんどの場合、データを生成する真のメカニズムは未知
- 解析者（人間）が指定する統計モデルは、データの分布に関する「仮定」にすぎない
- 仮定が正しい保証はない。ほとんどの場合、仮説は厳密には wrong
- しかし、データの特徴をうまく捉え、データの分布をほぼ近似するモデルであれば、解析目的（説明や予測）は十分達成されうる（useful となりうる）

統計モデリングとは？

- データに対して、統計モデルを仮定するという行為
- 厳密には wrong であっても useful なモデルを指定する試み
- データの特徴、過去の知見（生物学・臨床科学等）、そして、データ解析の目的を適切に考慮する必要がある

統計モデリングは一種のアート！

データをうまく捉え、表現することの“センス”がものをいう
（データ解析者の腕の見せ所）

回帰モデル regression models

- 興味のある変数 Y . その挙動を別の変数 X を用いて表現
- いいかえると、 Y を X の関数として表現
 - X は一つの変数でもよいし、複数の変数をまとめたものでもよい
 - 例えば、特定の疾患の発生 Y . 曝露変数やその他の変数をまとめて X
- 回帰モデルは、 Y と X の “関連性” を表現. それ自体に因果関係の概念はない
 - Y が原因、 X が結果でもよい
- いくつかの呼称：
 - 変数 Y は、目的変数、変数 X は説明変数
 - 変数 Y は、従属変数、変数 X は独立変数
 - 医学研究では、 X を共変量 (covariate) と呼ぶことも多い

回帰モデル：二種類のモデルから構成

- 平均構造モデル
 - X が変動することで Y の平均がどう変化するかを表現
 - 言い換えれば、 Y の平均を X の関数として指定
- 誤差モデル（誤差分布）
 - X を与えたときの観察データとしての Y のばらつき（誤差）の分布を指定
 - 多くは理論的な確率分布を指定（正規分布、ベルヌーイ分布、ポアソン分布など）

親子の身長の例：線形単回帰モデル

$$Y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\text{平均構造}} + \underbrace{\varepsilon_i}_{\text{誤差}} \quad (i = 1, \dots, 313)$$

Y : 子供の身長
(inches)

誤差モデル


$$\varepsilon \sim N(\mu(x), \sigma^2)$$

平均構造モデル

Y の平均値 (期待値)

$$\mu(x) = \beta_0 + \beta_1 x$$

Y は平均 $\mu(x)$, 分散 σ^2 の
正規分布に従う
(誤差 ε は平均0, 分散 σ^2 の
正規分布に従う)




x : 親の身長 (inches) 10

線形モデル（線形の仮定）が意味すること

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

- 変数 X （親の身長）が1インチ大きくなると、変数 Y （子の身長）は β_1 インチだけ大きくなる
- データセット上に実在しない親子の身長であっても成立。つまり、身長を取り得る値全体に対しての仮定。つまり、“外挿”している
- 効果 β_1 はどの X の値でも同じ（身長が低い親でも高い親でも同じ）
 - ただし、この仮定は緩和可能（例えば、 X^2 や X^3 などの高次の項を追加した曲線の仮定）




目的変数 Y のタイプに応じた指定

- 先の身長例では Y は子供の身長．連続量を想定した統計モデル
- 正の連続量に対しては、対数変換などの分散安定化・正規化変換が多用される（第5回「データの記述」の講義参照）
- 変換後の Y は、マイナスからプラスまで幅広い値をとりうる（基本的に制限なし）
- 多くの場合、誤差分布に正規分布を仮定することが妥当
- 一方、 Y が離散変数（例えば、疾患発生の有無）の場合はそうとはいかない．別の指定が必要となる

目的変数 Y が二値データの場合

- 例えば、 Y が疾患発生の有無、治療後の反応の有無、など
- 自然な誤差モデル（誤差分布）は、ベルヌーイ分布



$$\Pr(Y = 0) = 1 - p$$

$$\Pr(Y = 1) = p$$

“Pr” は Probability の略
括弧内の確率を表す


Y の平均（期待値）は、
 $Y = 1$ となる確率 p となる

補足) Y の平均
 $= 0 \times (1-p) + 1 \times p = p$

誤差分布：確率 p をもつベルヌーイ分布

目的変数 Y がカウントデータの場合

- 例えば、患者あたりの疾患再発数、有害事象の発現数、など
- 標準的な誤差モデル（誤差分布）は、ポアソン分布




誤差分布：平均 μ をもつポアソン分布

目的変数 Y が二値やカウントデータの場合 の平均構造モデル

- いずれの場合であれ、説明変数 X の線形式として指定は可能

$$\text{二値データ： } p(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K$$

$$\text{カウントデータ： } \mu(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K$$



- しかし、 $p(x)$ の取り得る範囲は0-1、 $\mu(x)$ の取り得る範囲は正值．線形式を当てはめると、その範囲から外れるものが出てくる
- $p(x)$ や $\mu(x)$ に特定の変換を施して範囲の制限を取り除く（変換後は $-\infty$ から ∞ まで取り得るものとする）．その上で線形式を指定する

目的変数 Y が二値やカウントデータの場合の 代表的な回帰モデル

- Y が二値データ、ベルヌーイ分布を仮定する場合：

$$\log \left\{ \frac{p(x)}{1-p(x)} \right\} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K$$

ロジット変換

ロジスティック
回帰モデル

注： $p(x)/(1-p(x))$ はオッズ比．その対数は対数
オッズ比

- Y がカウントデータ、ポアソン分布を仮定する場合：

$$\log\{\mu(x)\} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K$$

対数変換

ポアソン
回帰モデル

統計モデルと回帰モデルの基礎

- 統計モデル・回帰モデルとは？（午前の講義の復習）
- 線形回帰モデルによる解析
- ロジスティック回帰モデルによる解析

線形単回帰モデル

問題設定(連続値アウトカム)

- 説明変数: 1週間あたりの運動時間(分)
- 被説明変数: 収縮期血圧(mmHg)

に対して次のような関係を仮定

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- Y_i : 個人 i の収縮期血圧
- X_i : 個人 i の1週間あたりの運動時間
- β_0 : 切片
- β_1 : 傾き
- ε_i : 誤差項

線形単回帰モデル

サンプルコード

1. 環境設定

```
# 乱数の再現性を確保する  
set.seed(123)  
  
# 数値表示を見やすくする  
options(digits = 4)
```

線形単回帰モデル

サンプルコード

2. 擬似データの生成

```
n <- 120 # データ数

exercise_min <- round(runif(n, min = 0, max = 180)) # 1週間あたりの運動時間 (分)

# 真の関係：運動時間が長いほど平均的には血圧が低い、という設定
sbp <- 145 - 0.12 * exercise_min + rnorm(n, mean = 0, sd = 8)

df_lm <- data.frame(
  exercise_min = exercise_min,
  sbp = sbp
)

head(df_lm)
```

線形単回帰モデル

サンプルコード

2. 擬似データの生成

```
n <- 120 # データ数
```

```
exercise_min <- round(runif(n, min = 0, max = 180)) # 1週間あたりの運動時間 (分)
```

```
# 真の関係：運動時間が長いほど平均的には血圧が低い、という設定
```

```
sbp <- 145 - 0.12 * exercise_min + rnorm(n, mean = 0, sd = 8)
```

```
df_lm <- data.frame(  
  exercise_min = exercise_min,  
  sbp = sbp  
)
```

```
head(df_lm)
```

「運動時間」と「血
圧」のデータをセット
に

- `runif()` : 0-180の間からランダム（一様分布）に120個の数値を引く
- `round()` : 関数で四捨五入して数値を丸める

- `145 - 0.12 * exercise_min` : ベースの血圧を145とし、運動が1分増えるごとに血圧が0.12下がる直線を想定
- `rnorm(n, mean = 0, sd = 8)` : 平均0、標準偏差8の正規ノイズ

線形単回帰モデル

サンプルコード

2. 擬似データの生成: 実行結果

A data.frame: 6 × 2

	exercise_min	sbp
	<dbl>	<dbl>
1	52	141.8
2	142	123.9
3	74	133.5
4	159	117.8
5	169	116.1
6	8	146.5

線形単回帰モデル

サンプルコード

3. データの要約(最初にデータの基本的な特徴を確認)

```
summary(df_lm)
```

```
cor(df_lm$exercise_min, df_lm$sbp)
```

実行結果

説明変数の
quantile

	exercise_min
Min.	: 0.0
1st Qu.:	48.8
Median	: 86.5
Mean	: 92.0
3rd Qu.:	138.0
Max.	:179.0

	sbp
Min.	:112
1st Qu.:	129
Median	:134
Mean	:134
3rd Qu.:	140
Max.	:155

被説明変数の
quantile

```
-0.510989164752125
```

説明変数と被説明変数
の相関係数 (ピアソ
ン)

線形単回帰モデル

サンプルコード

4. 散布図の作成(説明変数と被説明変数の関係を可視化)

```
plot(  
  df_lm$exercise_min,  
  df_lm$sbp,  
  xlab = "Exercise time per week (minutes)",  
  ylab = "Systolic blood pressure (mmHg)",  
  main = "Exercise time and systolic blood pressure",  
  pch = 19  
)
```


線形単回帰モデル

サンプルコード

4. 散布図の作成(説明変数と被説明変数の関係を可視化)

```
plot(df_lm$exercise_min, df_lm$sbp,
      xlab = "Exercise time per week (minutes)",
      ylab = "Systolic blood pressure (mmHg)",
      main = "Exercise time and systolic blood pressure",
      pch = 19
)
```

散布図を描画する組み込み関数

散布図のx軸になる変数


散布図のy軸になる変数

線形単回帰モデル

サンプルコード

4. 散布図の作成

実行結果



線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

Rでは、線形回帰モデルを `lm()` で推定できる.

基本形は次の通り：

```
lm(目的変数 ~ 説明変数, data = データフレーム)
```

線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

```
fit_lm <- lm(sbp ~ exercise_min, data = df_lm)

fit_lm
```

線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

```
fit_lm <- lm(sbp ~ exercise_min, data = df_lm)
```

被説明変数

説明変数

fit_lm

線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

実行結果

Call:

```
lm(formula = sbp ~ exercise_min, data = df_lm)
```

Coefficients:

(Intercept)	exercise_min
141.7837	-0.0872

線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

実行結果

```
Call:  
lm(formula = sbp ~ exercise_min, data = df_lm)
```

当てはめたモデルの形式

Coefficients:

(Intercept)

141.7837

切片項 `beta_0`

exercise_min

-0.0872

回帰係数 `beta_1`

推定されたパラメータ

線形単回帰モデル

サンプルコード

5. 線形単回帰モデルの推定

```
summary(fit_lm)
```

`fit_lm` に格納された膨大な分析結果から人間が見て分かりやすい形式にまとめたレポートを出力

線形単回帰モデル

サンプルコード

```
summary(fit_lm)
```

実行結果

Call:

```
lm(formula = sbp ~ exercise_min, data = df_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.948	-4.723	-0.242	4.146	23.500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	141.7837	1.4220	99.70	< 2e-16 ***
exercise_min	-0.0872	0.0135	-6.46	2.5e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.6 on 118 degrees of freedom

Multiple R-squared: 0.261, Adjusted R-squared: 0.255

F-statistic: 41.7 on 1 and 118 DF, p-value: 2.47e-09

線形単回帰モデル

サンプルコード

```
summary(fit_lm)
```

実行結果

```
Call:
lm(formula = sbp ~ exercise_min, data = df_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.948	-4.723	-0.242	4.146	23.500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	141.7837	1.4220	99.70	< 2e-16 ***
exercise_min	-0.0872	0.0135	-6.46	2.5e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.6 on 118 degrees of freedom
Multiple R-squared: 0.261, Adjusted R-squared: 0.255
F-statistic: 41.7 on 1 and 118 DF, p-value: 2.47e-09

当てはめたモデルの形式

残差のquantile：実際のデータが予測した直線からどれくらい上下にズレて分布しているかを示す

線形単回帰モデル

サンプルコード

```
summary(fit_lm)
```

実行結果

Call:

```
lm(formula = sbp ~ exercise_min, data = df_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.948	-4.723	-0.242	4.146	23.500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	141.7837	1.4220	99.70	< 2e-16 ***
exercise_min	-0.0872	0.0135	-6.46	2.5e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

パラメータの

- 推定値
- 標準誤差
- t統計量
- p値

予測の平均的な
ずれの大きさ

Residual standard error: 7.6 on 118 degrees of freedom

Multiple R-squared: 0.261, Adjusted R-squared: 0.255

F-statistic: 41.7 on 1 and 118 DF, p-value: 2.47e-09

線形単回帰モデル

サンプルコード

```
summary(fit_lm)
```

実行結果

```
Call:
lm(formula = sbp ~ exercise_min, data = df_lm)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.948	-4.723	-0.242	4.146	23.500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	141.7837	1.4220	99.70	< 2e-16 ***
exercise_min	-0.0872	0.0135	-6.46	2.5e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.6 on 118 degrees of freedom

Multiple R-squared: 0.261, Adjusted R-squared: 0.255

F-statistic: 41.7 on 1 and 118 DF, p-value: 2.47e-09

モデルに対する F検定

- データの分散のうち、どれだけ説明変数によって説明されているかと、どれだけ説明されずに残っているかを比較
- もし説明変数が「ノイズ」に対して多くの分散を説明している場合、F値は大きくなる

重決定係数：
モデルが実際の
データをどれく
らい正確に説明
できているかを
示す「モデルの
当てはまりの良
さ（0～1）」

モデルに対する F検定の結果

線形単回帰モデル

サンプルコード

6. 回帰係数の取り出し

`coef()` を使うと推定された切片と傾きを取り出せる

```
coef(fit_lm)
```

実行結果

(Intercept): 141.783692345608 exercise_min: -0.0871846699385855

線形単回帰モデル

サンプルコード

6. 回帰係数の取り出し

`coef()` を使うと推定された切片と傾きを取り出せる

```
coef(fit_lm)
```

実行結果

(Intercept):	141.783692345608	exercise_min:	-0.0871846699385855
--------------	------------------	---------------	---------------------

切片項

説明変数の回帰係数

線形単回帰モデル

サンプルコード

6. 回帰係数の取り出し

`coef()` を使うと推定された切片と傾きを取り出せる

```
beta0_hat <- coef(fit_lm)[1]  
beta1_hat <- coef(fit_lm)[2]  
  
beta0_hat  
beta1_hat
```

`coef`はベクトル形式になっているのでインデックス指定で係数毎に個別に取り出せる

実行結果

```
(Intercept): 141.783692345608  
exercise_min: -0.0871846699385855
```

線形単回帰モデル

7. 回帰係数の解釈

このモデルは次の形で書ける：

$$\widehat{\text{SBP}} = \hat{\beta}_0 + \hat{\beta}_1 \times \text{Exercise}$$

傾き $\hat{\beta}_1$ は,

運動時間が1分増えたとき、平均的な収縮期血圧が
何 mmHg 変化するか

を表す.

例えば, $\hat{\beta}_1 = -0.12$ 程度であれば,

1週間あたりの運動時間が1分増えると、収縮期血圧
は平均的に約0.12 mmHg低い

と解釈する.

線形単回帰モデル

サンプルコード

8. 回帰直線の可視化

散布図に推定された回帰直線を重ねて表示

```
plot(  
  df_lm$exercise_min,  
  df_lm$sbp,  
  xlab = "Exercise time per week (minutes)",  
  ylab = "Systolic blood pressure (mmHg)",  
  main = "Simple linear regression",  
  pch = 19  
)  
  
abline(fit_lm, lwd = 2)
```

線形単回帰モデル

サンプルコード

8. 回帰直線の可視化

散布図に推定された回帰直線を重ねて表示

`fit_lm` の中から自動的に「切片（ベースの血圧）」と「傾き（運動時間の影響度）」の数値を読み取って対応する直線を引く

```
plot(  
  df_lm$exercise_min,  
  df_lm$sbp,  
  xlab = "Exercise time per week (minutes)",  
  ylab = "Systolic blood pressure (mmHg)",  
  main = "Simple linear regression",  
  pch = 19  
)
```

```
abline(fit_lm, lwd = 2)
```


散布図を書くコード
(前と同じ)

線形単回帰モデル

サンプルコード

8. 回帰直線の可視化

実行結果



線形単回帰モデル

サンプルコード

9. 回帰係数の信頼区間の計算

`confint()` を使うと回帰係数の信頼区間を計算できる.

```
confint(fit_lm)
```

実行結果

A matrix: 2 × 2 of type dbl

2.5 %

97.5 %

(Intercept)	138.9677	144.59971
exercise_min	-0.1139	-0.06045

線形単回帰モデル

サンプルコード

10. 予測

推定されたモデルを使って、新しい運動時間に対する血圧の平均値を予測できる

```
new_lm <- data.frame(  
  exercise_min = c(0, 30, 60, 120, 180)  
)  
  
predict(fit_lm, newdata = new_lm)
```

線形単回帰モデル

サンプルコード

10. 予測

推定されたモデルを使って、新しい運動時間に対する血圧の平均値を予測できる

```
new_lm <- data.frame(  
  exercise_min = c(0, 30, 60, 120, 180)  
)
```

予測対象の新たなデータ点（説明変数）

```
predict(fit_lm, newdata = new_lm)
```

predict() 関数で予測

線形単回帰モデル

サンプルコード

10. 予測

実行結果

1: 141.783692345608 2: 139.168152247451 3: 136.552612149293 4:
131.321531952978 5: 126.090451756663

```
exercise_min = c(0, 30, 60, 120, 180)
```

の各点に対する線形モデルによる予測結果

統計モデルと回帰モデルの基礎

- 統計モデル・回帰モデルとは？（午前の講義の復習）
- 線形回帰モデルによる解析
- ロジスティック回帰モデルによる解析

ロジスティック回帰モデル

問題設定(2値アウトカム)

- 説明変数: 年齢
- 被説明変数: 疾患の有無 (0: 無, 1: 有)

に対して, ある年齢の人が対象疾患に罹患している確率

$$p_i = P(Y_i = 1 \mid X_i)$$

が知りたいとする.

ロジスティック回帰モデル

ある年齢の人が対象疾患に罹患している確率

$$p_i = P(Y_i = 1 \mid X_i)$$

が知りたいとする.

ロジスティック回帰では, p_i を以下のようにモデル化する

$$\log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \beta_1 X_i$$

ロジスティック回帰モデル

ある年齢の人が対象疾患に罹患している確率

$$p_i = P(Y_i = 1 \mid X_i)$$

が知りたいとする. ロジスティック回帰では, p_i を以下のようにモデル化する(**一般化線形モデル**)

$$\log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \beta_1 X_i$$

対数オッズ
確率を直線的な数式で扱えるよう
に実数全体に引き伸ばしたもの

線形モデル

ロジスティック回帰モデル

サンプルコード

1. 擬似データの生成

```
set.seed(456)

n <- 200

age <- round(runif(n, min = 30, max = 80))

# 真の発症確率をロジスティック関数で設定
# 年齢が高いほど疾患ありの確率が高くなる, という設定
linear_predictor <- -7 + 0.09 * age
prob_disease <- 1 / (1 + exp(-linear_predictor))

disease <- rbinom(n, size = 1, prob = prob_disease)

df_glm <- data.frame(
  age = age,
  disease = disease
)

head(df_glm)
```

ロジスティック回帰モデル

サンプルコード

1. 擬似データの生成

ロジスティックモデル
の線形モデル部分

真の p_i

疾患の有無を表す2値
アウトカムデータ

```
set.seed(456)
```

```
n <- 200
```

一様分布によって30歳から80歳
までの年齢データを200件生成

```
age <- round(runif(n, min = 30, max = 80))
```

```
# 真の発症確率をロジスティック関数で設定
```

```
# 年齢が高いほど疾患ありの確率が高くなる, という設定
```

```
linear_predictor <- -7 + 0.09 * age
```

```
prob_disease <- 1 / (1 + exp(-linear_predictor))
```

```
disease <- rbinom(n, size = 1, prob = prob_disease)
```

```
df_glm <- data.frame(  
  age = age,  
  disease = disease  
)
```

```
head(df_glm)
```

ロジスティック回帰モデル

サンプルコード

1. 擬似データの生成

実行結果

A data.frame: 6 × 2

	age	disease
	<dbl>	<int>
1	34	0
2	41	0
3	67	1
4	73	0
5	69	0
6	47	0

ロジスティック回帰モデル

サンプルコード

2. データの要約

まず疾患の有・無(被説明変数)の人数を確認

```
table(df_glm$disease)
```

単純な頻度の集計

実行結果

0	1
162	38

```
prop.table(table(df_glm$disease))
```

相対頻度の集計

0	1
0.81	0.19

ロジスティック回帰モデル

サンプルコード

2. データの要約

次に年齢(説明変数)の分布も確認

```
summary(df_glm$age)
```

実行結果

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
30.0	45.8	57.0	57.2	70.0	80.0

ロジスティック回帰モデル

サンプルコード

3. 散布図の作成

変数は0または1なので点が重なりやすくなる

→ `jitter()` を使って縦方向に少しだけずらして表示

```
plot(  
  df_glm$age,  
  jitter(df_glm$disease, amount = 0.05),  
  xlab = "Age",  
  ylab = "Disease status",  
  main = "Age and disease status",  
  pch = 19,  
  yaxt = "n"  
)  
axis(2, at = c(0, 1), labels = c("No disease", "Disease"))
```

ロジスティック回帰モデル

サンプルコード

3. 散布図の作成

変数は0または1なので点が重なりやすくなる

→ `jitter()` を使って縦方向に少しだけずらして表示

```
plot(  
  df_glm$age,  
  jitter(df_glm$disease, amount = 0.05),  
  xlab = "Age",  
  ylab = "Disease status",  
  main = "Age and disease status",  
  pch = 19,  
  yaxt = "n"  
)  
axis(2, at = c(0, 1), labels = c("No disease", "Disease"))
```


`amount` オプションで各点をどれ
だけずらして表示するかを制御

ロジスティック回帰モデル

サンプルコード

3. 散布図の作成

実行結果



ロジスティック回帰モデル

サンプルコード

4. ロジスティック回帰のフィッティング

ロジスティック回帰は `glm()` 関数で推定できる.

基本形は次の通り:

```
glm(目的変数 ~ 説明変数, data = データフレーム, family = binomial)
```

ロジスティック回帰モデル

サンプルコード

4. ロジスティック回帰のフィッティング

```
fit_glm <- glm(disease ~ age, data = df_glm, family = binomial)
```

```
fit_glm
```

ロジスティック回帰モデル

サンプルコード

4. ロジスティック回帰のフィッティング

実行結果

```
Call: glm(formula = disease ~ age, family = binomial, data = df_glm)
```

```
Coefficients:
```

(Intercept)	age
-9.250	0.122

```
Degrees of Freedom: 199 Total (i.e. Null); 198 Residual
```

```
Null Deviance: 194
```

```
Residual Deviance: 143 AIC: 147
```

ロジスティック回帰モデル

サンプルコード

4. ロジスティック回帰のフィッティング

実行結果

当てはめたモデルの形式

```
Call: glm(formula = disease ~ age, family = binomial, data = df_glm)
```

Coefficients:

(Intercept)	age
-9.250	0.122

切片と回帰係数の推定値

自由度（切片だけモデル，説明変数入りモデル）

```
Degrees of Freedom: 199 Total (i.e. Null); 198 Residual
```

```
Null Deviance: 194
```

```
Residual Deviance: 143 AIC: 147
```

逸脱度とAICによるモデル評価

ロジスティック回帰モデル

サンプルコード

5. 推定結果の詳細

```
summary(fit_glm)
```

実行結果

```
Call:
glm(formula = disease ~ age, family = binomial, data = df_glm)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -9.2497      1.5489  -5.97  2.3e-09 ***
age           0.1225      0.0224   5.46  4.8e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 194.49  on 199  degrees of freedom
Residual deviance: 143.23  on 198  degrees of freedom
AIC: 147.2

Number of Fisher Scoring iterations: 6
```


ロジスティック回帰モデル

サンプルコード

実行結果

5. 推定結果の詳細

```
summary(fit_glm)
```

パラメータの

- 推定値
- 標準誤差
- z統計量
- p値

Call:

```
glm(formula = disease ~ age, family = binomial, data = df_glm)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-9.2497	1.5489	-5.97	2.3e-09	***
age	0.1225	0.0224	5.46	4.8e-08	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 194.49 on 199 degrees of freedom
Residual deviance: 143.23 on 198 degrees of freedom
AIC: 147.2

Number of Fisher Scoring iterations: 6

ロジスティック回帰モデル

6. 回帰係数の解釈

ロジスティック回帰の係数はそのままでは **ログオッズ比** の単位
年齢の係数 $\hat{\beta}_1$ は,

年齢が1歳増えたとき、疾患ありのログオッズがどれだけ変化するか

を表す.

ただし、ログオッズは直感的に理解しにくいので、指数を取って **オッズ比** として解釈することが多い.

$$OR = \exp(\hat{\beta}_1)$$

ロジスティック回帰モデル

サンプルコード

7. 回帰係数の取り出し

```
coef(fit_glm)
```

実行結果 (Intercept): -9.24972385540721 age: 0.122497606092106

```
# 1歳増加あたりのオッズ比  
exp(coef(fit_glm)["age"])
```

実行結果 age: 1.13031641419739

「年齢が 1 歳上がるごとにその疾患に罹患するリスクが約1.13 倍」と解釈

ロジスティック回帰モデル

サンプルコード

8. 係数の信頼区間

`confint.default()` を使うと近似に基づく信頼区間を計算できる

その指数を取ることによってオッズ比の信頼区間が得られる。

```
coef_table <- cbind(  
  Estimate = coef(fit_glm),  
  OR = exp(coef(fit_glm)),  
  OR_lower = exp(confint.default(fit_glm)[, 1]),  
  OR_upper = exp(confint.default(fit_glm)[, 2])  
)
```

信頼区間の下限の値

信頼区間の上限の値

coef_table

ロジスティック回帰モデル

サンプルコード

8. 係数の信頼区間

実行結果

A matrix: 2 × 4 of type dbl

	Estimate	OR	OR_lower	OR_upper
(Intercept)	-9.2497	9.614e-05	4.619e-06	0.002001
age	0.1225	1.130e+00	1.082e+00	1.181157

ロジスティック回帰モデル

サンプルコード

9. 確率的な予測

`predict()` を使って新たなデータの予測ができる

ロジスティック回帰では `type = "response"` を指定すると、疾患ありの予測確率が得られる。

```
new_glm <- data.frame(  
  age = c(40, 50, 60, 70, 80)  
)  
  
pred_prob <- predict(fit_glm, newdata = new_glm, type = "response")  
  
cbind(new_glm, predicted_probability = pred_prob)
```

ロジスティック回帰モデル

サンプルコード

9. 確率的な予測

`predict()` を使って新たなデータの予測ができる

ロジスティック回帰では `type = "response"` を指定すると、疾患ありの予測確率が得られる。

```
new_glm <- data.frame(  
  age = c(40, 50, 60, 70, 80)  
)
```

予測対象の新たなデータ

`predict()` 関数による予測

```
pred_prob <- predict(fit_glm, newdata = new_glm, type = "response")
```

```
cbind(new_glm, predicted_probability = pred_prob)
```

ロジスティック回帰モデル

サンプルコード

9. 確率的な予測

実行結果

A data.frame: 5 × 2

age predicted_probability

<dbl>

<dbl>

1	40	0.01274
2	50	0.04209
3	60	0.13012
4	70	0.33740
5	80	0.63416

ロジスティック回帰モデル

サンプルコード

9. 確率的な予測

実行結果

A data.frame: 5 × 2

	age	predicted_probability
	<dbl>	<dbl>
1	40	0.01274
2	50	0.04209
3	60	0.13012
4	70	0.33740
5	80	0.63416

確率 ≥ 0.5 で $y=1$
確率 < 0.5 で $y=0$
というしきい値を取れば

$y=0$ (疾患でない) と予測

→ $y=1$ (疾患) と予測

提出課題

本日、最後の演習問題で、(1)71歳から79歳までの罹患確率を予測し、(2)しきい値を0.5としたときの罹患の有無の分類を行い、(1)および(2)を合わせて csvファイルとして保存して提出

提出方法:KULMSの課題提出機能

提出期限:7/1(水)23:55