

サンプルサイズ設計

医療データ科学実習
(Practice of Biomedical Data Science)

第13回 2026年7月14日

医療データ科学

matsui.kota.8k@kyoto-u.ac.jp

臨床統計学

emoto.ryo.5m@kyoto-u.ac.jp

質問はslidoでもOK

参加

URL: <https://app.sli.do/event/79DZaLiq9g68APLX7ZTqpw>



復習：仮説検定

仮説検定 hypothesis testing

- 帰無仮説 H_0 , 対立仮説 H_1 と有意水準を設定
 - 帰無仮説 H_0 : 多くの場合、差なし、関連なしの仮説
 - 対立仮説 H_1 : 多くの場合、差あり、関連ありの仮説 ← 研究者が主張したい仮説
 - 有意水準: 検定の結論を定めるための閾値
- データを観測し、データから P 値を計算する
 - P 値: 帰無仮説 H_0 の仮定の下で
観測された事象かそれ以上に極端な事象が起こる確率
- 帰無仮説 H_0 の棄却、受容を決定
 - P 値が有意水準以下の場合: 帰無仮説 H_0 を棄却
P 値が閾値 (有意水準より) 小さい $\Rightarrow$ 帰無仮説 H_0 の仮定が正しくなかった
 H_0 を強く否定できると同時に H_1 を積極的に主張できる
 - P 値が有意水準より大きい場合: 帰無仮説 H_0 を受容
 H_0 を否定する強い根拠は得られていない H_0 が正しいと積極的には主張できない

例: 新規がん治療の臨床試験

- 新規治療の腫瘍縮小率(反応率)についての仮説の設定
 - 帰無仮説 $H_0: p = 0.4$ (従来治療と差なし: 過去の治療成績から想定)
 - 対立仮説 $H_1: p > 0.4$ (従来治療より高い)
 - 有意水準: 0.05
 - データを観測し、データから P値を計算する
 - データ: 20名の患者を試験に登録し、新規治療を実施後に合計1名が反応
 - P値: 0.1275 (片側)
 - 帰無仮説 H_0 の棄却、受容を決定
 - P値(0.1275)が有意水準(0.05)以上なので、帰無仮説 H_0 を受容
 H_0 を否定する強い根拠は得られていない H_0 が正しいと積極的には主張できない
- 新規治療の反応率が従来治療より高いとは言えない

過誤確率の制御


検定結果	真の仮説	
	H_0	H_1
H_0 を棄却	第一種の誤り, α エラー (type I/alpha error)	正しい判定
H_0 を受容	正しい判定	第二種の誤り, β エラー (type II/beta error)

- 検定のロジックはType I error を有意水準以下に制御
- Type II error (β) / 検出力 ($1 - \beta$) は以下の要因により変わる
真の効果の大きさ、推定誤差、サンプルサイズ


例: 新規がん治療の臨床試験における検出力

- 新規治療の腫瘍縮小率(反応率)についての仮説検定
 - 帰無仮説 $H_0: p = 0.4$ (従来治療と差なし: 過去の治療成績から想定)
 - 対立仮説 $H_1: p > 0.4$ (従来治療より高い)
 - 有意水準: 0.025

サンプルサイズの影響(真の反応率: $p = 0.65$)



真の反応率の影響(サンプルサイズ: $n = 20$)



サンプルサイズ設計

- 検出力の一定水準の担保が目的
- 試験計画段階で、検出力が閾値以上となるようサンプルサイズを算出
- 検出力は対立仮説の下での真の効果サイズによっても変わるため
計算には効果サイズの指定が必要:
臨床的に意味のある最小限の効果サイズ
 - ー 真の効果サイズが大きくなると、検出力は大きくなる
→ 最小の効果サイズでサンプルサイズ設計すればよい

サンプルサイズ設計

- 一群の割合の差の検定
- 二群の検定
 - 連続アウトカム: 平均の差
 - 二値アウトカム: 割合の差
 - 生存時間アウトカム

必要サンプルサイズの算出

- 事前に設定するもの
 - **目標検出力**
 - 帰無仮説: 棄却したい仮説
 - 対立仮説: 研究で支持したい仮説
 - 有意水準: 許容するType I errorの確率の上限
 - 検出したい最小の効果: 臨床的観点から設定
 - 検定手法: データや分布に関する仮定を含む
- 計算によって求めるもの
 - 目標検出力を達成するために必要なサンプルサイズ

一群の割合の検定: 新規がん治療の臨床試験

- 事前に設定するもの

- 目標検出力: 0.8
- 帰無仮説: $H_0: p = 0.4$
- 対立仮説: $H_1: p > 0.4$
- 有意水準: 0.025
- 検出したい最小の効果: $p = 0.65$
- 検定手法: 一群の割合の検定

仮定:

観測される反応ありの例数は二項分布に従う

一群の割合の検定におけるサンプルサイズ計算

- ライブラリのインストール、読み込み

```
> install.packages("pwr")  
> library(pwr)
```

- pwr パッケージの `pwr.p.test()` 関数による計算
 - 一群の割合の差の検定の検出力計算、サンプルサイズ計算の関数

```
> p0 <- 0.4  
> p_true <- 0.65  
> h = ES.h(p_true, p0)  
> pwr.p.test(h=h, sig.level = 0.025, power = 0.8, alternative = "greater")
```

各仮説の下での反応率

効果の大きさの算出

効果の大きさ

有意水準

検出力

片側検定

一群の割合の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.p.test()` 関数による計算

```
> pwr.p.test(h=h, sig.level = 0.025, power = 0.8, alternative = "greater")
```

proportion power calculation for binomial distribution (arcsine transformation)

```
h = 0.5060506
```

```
n = 30.64925
```

必要サンプルサイズ


```
sig.level = 0.025
```

```
power = 0.8
```

```
alternative = greater
```

必要サンプルサイズは31例

先週計算した数値結果ともほぼ一致
(近似計算をしている)



二群の平均の検定: 降圧薬

演習

標準治療での12週後のSBP低下は平均10 mmHg、新薬では15 mmHg低下が期待される(差=5 mmHg、SD=10 mmHgと仮定)。

等割付、片側検定、 $\alpha=0.025$ 、 $\beta=0.20$ で必要な症例数は何例か？

- 事前に設定するもの
 - 有意水準: 0.025, 目標検出力: 0.8
 - 12週後のSBP低下の分布についての仮定:
標準治療 $N(\mu_1, \sigma^2)$, 新薬 $N(\mu_2, \sigma^2)$, $\sigma=10$
 - 帰無仮説: $H_0: \mu_1 = \mu_2$, 対立仮説: $H_1: \mu_1 < \mu_2$
 - 検出したい最小の効果: $\mu_2 - \mu_1 = 5$

二群の平均の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.t.test()` 関数による計算
 - 二群の平均の差の検定の検出力計算、サンプルサイズ計算の関数

```
> d <- 5/10  
> pwr.t.test(d=d, sig.level = 0.025, power = 0.8, alternative = "greater")
```

効果の大きさ

有意水準

検出力

片側検定

Two-sample t test power calculation

```
n = 63.76561
```

```
d = 0.5
```

```
sig.level = 0.05
```

```
power = 0.8
```

```
alternative = two.sided
```

必要サンプルサイズ

NOTE: n is number in *each* group


参考：関数の中でやっていること

$$\text{検定統計量: } Z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{2\sigma^2/n}} \sim N\left(\frac{\mu_1 - \mu_2}{\sqrt{2\sigma^2/n}}, 1\right)$$

$\bar{x}_1$: 標準治療でのSBP低下の平均

$\bar{x}_2$: 新薬でのSBP低下の平均

この式を満たすnを求める



数値の確認

- `pwr.t.test()` 関数による計算結果を用いて検出力を確認


```
> res_t <- pwr.t.test(d=d, sig.level = 0.025, power = 0.8, alternative = "greater")
> str(res_t)
List of 7
 $ n      : num 63.8 — 必要サンプルサイズ
 $ d      : num 0.5
 $ sig.level : num 0.025
 $ power   : num 0.8
 $ alternative: chr "greater"
 $ note    : chr "n is number in *each* group"
 $ method   : chr "Two-sample t test power calculation"
 - attr(*, "class")= chr "power.htest"
>
> print(res_t$n)
[1] 63.76576
> print(qnorm(0.975))
[1] 1.959964
>
> pnorm(qnorm(0.975), mean = 5/(sqrt(2*10^2/(res_t$n))), sd = 1, lower.tail = FALSE)
[1] 0.8060089 — 検出力
```

Δ
 $\sqrt{2\sigma^2/n}$

検出力曲線と必要サンプルサイズの視覚化

- `pwr.t.test()` 関数による結果は `plot()` 関数により ggplotオブジェクトとして扱える

```
> library(ggplot2)
> g <- plot(res_t, cex=2) +
+   theme_classic(base_size = 12)
>
> g
```



二群の割合の検定: 不眠症の治療薬

演習

既存の治療薬の成功率が30%であり、新しい治療薬で50%の成功率が見込まれる状況でRCTを実施するとして。

等割付、片側検定、 $\alpha=0.025$ 、 $\beta=0.20$ のもとで必要な症例数は何例か？

- 事前に設定するもの
 - 有意水準: 0.025, 目標検出力: 0.8
 - 治療成功の症例数の分布についての仮定:
既存治療 $B(n, p_1)$, 新治療 $B(n, p_2)$
 - 帰無仮説: $H_0: p_1 = p_2$, 対立仮説: $H_1: p_1 < p_2$
 - 検出したい最小の効果: $p_2 - p_1 = 0.5 - 0.3 = 0.2$

二群の平均の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.2p.test()` 関数による計算
 - 近似を用いた計算手法

```
> p1 <- 0.3
> p2 <- 0.5
> h <- ES.h(p2, p1)
> res_prop_test <- pwr.2p.test(h = h, sig.level = 0.025, power = 0.8, alternative = "greater")

> res_prop_test
```

効果の大きさの算出

効果の大きさ 有意水準 検出力 片側検定

Difference of proportion power calculation for binomial distribution (arcsine transformation)

```
      h = 0.4115168
      n = 92.69631
sig.level = 0.025
power = 0.8
alternative = greater
```

必要サンプルサイズ


NOTE: same sample sizes

検出力曲線と必要サンプルサイズの視覚化

- `pwr.2p.test()` 関数による結果は `plot()` 関数により `ggplot` オブジェクトとして扱える

```
library(ggplot2)
g <- plot(res_prop_test, cex=2) +
  theme_classic(base_size = 12)

g
```



シミュレーションによるサンプルサイズ設計

第12回の演習で行った方法を1例ずつ変えて行う

演習:

以下の検定問題においてサンプルサイズを $n = 10, 20, \dots$ と変えていったとき, 検出力がどのように変化するか観察してみよう

- $H_0: p_{\text{new}} = p_0$ vs $H_1: p_{\text{new}} > p_0$ (片側検定)
 - $p_0 = 0.4$ (帰無仮説の反応率)
 - $p_{\text{new}} = 0.65$ (対立仮説の真の反応率)
- 有意水準 $\alpha = 0.025$
- 検定統計量 $X(\sim \text{Binom}(n, p))$: 反応回数
- シミュレーション回数: 2000回

シミュレーションによるサンプルサイズ計算

- シミュレーションの設定

```
set.seed(123)           # 乱数シード固定
alpha               <- 0.025 # 有意水準（片側）
p0                  <- 0.4   # 帰無仮説下の反応率
p_true              <- 0.65  # 真の反応率（> p0）
nsim                 <- 2000  # シミュレーション回数
sample_sizes <- seq(20, 50, by = 1) # サンプルサイズの設定 1例ずつ
```

シミュレーションによるサンプルサイズ計算

- シミュレーションの実行

```
sim_power      <- numeric(length(sample_sizes))
theory_power   <- numeric(length(sample_sizes))

for (i in seq_along(sample_sizes)) {
  n <- sample_sizes[i]

  ## ---- 片側棄却域（上側） -----
  # crit は  $P_{H_0}(X > \text{crit}) \leq \alpha$  を満たす最大の閾値
  # 棄却条件:  $X > \text{crit}$ 
  crit <- qbinom(1 - alpha, n, p0) # 小さいほうの分位点

  # シミュレーション検出力
  x_sim      <- rbinom(nsim, n, p_true)
  sim_power[i] <- mean(x_sim > crit)

  # 理論検出力
  theory_power[i] <- 1 - pbinom(crit, n, p_true)
}
```


シミュレーションによるサンプルサイズ計算

- 検出力曲線の描画

```
df <- data.frame(  
  n = c(sample_sizes, sample_sizes),  
  power = c(sim_power, theory_power),  
  group = c(rep("simulation", length(sim_power)), rep("theory",  
length(theory_power)))  
)  
  
library(ggplot2)  
g <- ggplot(data = df, aes(x = n, y = power, group = group)) +  
  geom_line(aes(color = group)) +  
  geom_point(aes(color = group)) +  
  theme_bw(base_size = 18)  
print(g)
```


シミュレーションによるサンプルサイズ計算

- 検出力曲線
一例ずつ増やすと
単調増加でない
- 閾値を
 $P_{\{H_0\}}(X > \text{crit}) \leq \alpha$ を満たす
最大の閾値
として設定
- 離散変数なので
 α が有意水準から
大きく離れる場合がある



シミュレーションによるサンプルサイズ計算

- 閾値に対応した第一種の過誤確率の計算の追加

```
sim_power      <- numeric(length(sample_sizes))
theory_power   <- numeric(length(sample_sizes))
theory_alpha   <- numeric(length(sample_sizes))

for (i in seq_along(sample_sizes)) {
  n <- sample_sizes[i]

  crit <- qbinom(1 - alpha, n, p0) # 小さいほうの分位点


  x_sim      <- rbinom(nsim, n, p_true)
  sim_power[i] <- mean(x_sim > crit)

  theory_power[i] <- 1 - pbinom(crit, n, p_true)

  # 第一種の過誤確率の実際の値
  theory_alpha[i] <- 1 - pbinom(crit, n, p0)
}
```


シミュレーションによるサンプルサイズ計算

- 第一種の過誤と第二種の過誤はトレードオフの関係
- 第一種の過誤が0.025より小さい
→ 第二種の過誤が大きくなる
= 検出力が小さくなる
- 検出力が設定を下回らない
最小のサンプルサイズ /
第一種の過誤が0.025に近く
検出力を達成する最小のサンプルサ



正確な確率による計算と近似による計算

- 新規がん治療の臨床試験の例
 - 近似による計算
 $n = 31$
 - 正確確率による計算
 $n = 32$
- 注意が必要
 - n が少ない時
 - 確率が0,1に近いとき
- 臨床試験においては脱落割合なども考慮される



提出課題

p. 18の演習において、以下の設定でp. 20のサンプルサイズ計算の結果の入った検出力曲線を描画し、画像ファイルとして保存したものを提出

- 既存の治療薬の成功率が40%
- 新しい治療薬で65%の成功率が見込まれる
- 残りの設定はp. 18と同様

提出方法: KULMSの課題提出機能

提出期限: 7/15(水)23:55

補足: arcsine変換・Cohen's h

`pwr.2p.test()` 関数における近似

中心極限定理より二項分布 $B(n, p)$ に従う標本の平均の漸近分布は

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

- 割合 p が 0 または 1 に近づくと分散が小さくなる
→ 同じ割合の差でも精度が異なる
- $\theta = 2 \cdot \arcsin(\sqrt{p})$ とすると、 $\Delta\theta$ の分散はほぼ一定になる
($\arcsin$ は逆正弦関数)
→ θ の差を効果量として用いる (Cohen's h)