

サンプルサイズ設計

医療データ科学実習
(Practice of Biomedical Data Science)

第13回 2026年7月14日

医療データ科学

matsui.kota.8k@kyoto-u.ac.jp

臨床統計学

emoto.ryo.5m@kyoto-u.ac.jp

質問はslidoでもOK

参加

URL: <https://app.sli.do/event/79DZaLiq9g68APLX7ZTqpw>



復習：仮説検定

仮説検定 hypothesis testing

- 帰無仮説 H_0 , 対立仮説 H_1 と有意水準を設定
 - 帰無仮説 H_0 : 多くの場合、差なし、関連なしの仮説
 - 対立仮説 H_1 : 多くの場合、差あり、関連ありの仮説 ← 研究者が主張したい仮説
 - 有意水準: 検定の結論を定めるための閾値
- データを観測し、データから P 値を計算する
 - P 値: 帰無仮説 H_0 の仮定の下で
観測された事象かそれ以上に極端な事象が起こる確率
- 帰無仮説 H_0 の棄却、受容を決定
 - P 値が有意水準以下の場合: 帰無仮説 H_0 を棄却
P 値が閾値 (有意水準より) 小さい $\Rightarrow$ 帰無仮説 H_0 の仮定が正しくなかった
 H_0 を強く否定できると同時に H_1 を積極的に主張できる
 - P 値が有意水準より大きい場合: 帰無仮説 H_0 を受容
 H_0 を否定する強い根拠は得られていない H_0 が正しいと積極的には主張できない

例: 新規がん治療の臨床試験

- 新規治療の腫瘍縮小率(反応率)についての仮説の設定
 - 帰無仮説 $H_0: p = 0.4$ (従来治療と差なし: 過去の治療成績から想定)
 - 対立仮説 $H_1: p > 0.4$ (従来治療より高い)
 - 有意水準: 0.05
 - データを観測し、データから P値を計算する
 - データ: 20名の患者を試験に登録し、新規治療を実施後に合計1名が反応
 - P値: 0.1275 (片側)
 - 帰無仮説 H_0 の棄却、受容を決定
 - P値(0.1275)が有意水準(0.05)以上なので、帰無仮説 H_0 を受容
 H_0 を否定する強い根拠は得られていない H_0 が正しいと積極的には主張できない
- 新規治療の反応率が従来治療より高いとは言えない

過誤確率の制御


検定結果	真の仮説	
	H_0	H_1
H_0 を棄却	第一種の誤り, α エラー (type I/alpha error)	正しい判定
H_0 を受容	正しい判定	第二種の誤り, β エラー (type II/beta error)

- 検定のロジックはType I error を有意水準以下に制御
- Type II error (β) / 検出力 ($1 - \beta$) は以下の要因により変わる
真の効果の大きさ、推定誤差、サンプルサイズ


例: 新規がん治療の臨床試験における検出力

- 新規治療の腫瘍縮小率(反応率)についての仮説検定
 - 帰無仮説 $H_0: p = 0.4$ (従来治療と差なし: 過去の治療成績から想定)
 - 対立仮説 $H_1: p > 0.4$ (従来治療より高い)
 - 有意水準: 0.025

サンプルサイズの影響(真の反応率: $p = 0.65$)



真の反応率の影響(サンプルサイズ: $n = 20$)



サンプルサイズ設計

- 検出力の一定水準の担保が目的
- 試験計画段階で、検出力が閾値以上となるようサンプルサイズを算出
- 検出力は対立仮説の下での真の効果サイズによっても変わるため
計算には効果サイズの指定が必要:
臨床的に意味のある最小限の効果サイズ
 - ー 真の効果サイズが大きくなると、検出力は大きくなる
→ 最小の効果サイズでサンプルサイズ設計すればよい

サンプルサイズ設計

- 一群の割合の差の検定
- 二群の検定
 - 連続アウトカム: 平均の差
 - 二値アウトカム: 割合の差
- 候補サンプルサイズの検出力評価による設計

必要サンプルサイズの算出

- 事前に設定するもの
 - **目標検出力**
 - 帰無仮説: 棄却したい仮説
 - 対立仮説: 研究で支持したい仮説
 - 有意水準: 許容するType I errorの確率の上限
 - 検出したい最小の効果: 臨床的観点から設定
 - 検定手法: データや分布に関する仮定を含む
- 計算によって求めるもの
 - 目標検出力を達成するために必要なサンプルサイズ

一群の割合の検定: 新規がん治療の臨床試験

- 事前に設定するもの

- 目標検出力: 0.8
- 帰無仮説: $H_0: p = 0.4$
- 対立仮説: $H_1: p > 0.4$
- 有意水準: 0.025
- 検出したい最小の効果: $p = 0.65$
- 検定手法: 一群の割合の検定

仮定:

観測される反応ありの例数は二項分布に従う

一群の割合の検定におけるサンプルサイズ計算

- ライブラリのインストール、読み込み

```
> install.packages("pwr")  
> library(pwr)
```

- pwr パッケージの `pwr.p.test()` 関数による計算
 - 一群の割合の差の検定の検出力計算、サンプルサイズ計算の関数

```
> p0 <- 0.4  
> p_true <- 0.65  
> h = ES.h(p_true, p0)  
> pwr.p.test(h=h, sig.level = 0.025, power = 0.8, alternative = "greater")
```

各仮説の下での反応率

効果の大きさの算出

効果の大きさ

有意水準

検出力

片側検定

一群の割合の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.p.test()` 関数による計算

```
> pwr.p.test(h=h, sig.level = 0.025, power = 0.8, alternative = "greater")
```

proportion power calculation for binomial distribution (arcsine transformation)

```
h = 0.5060506
```

```
n = 30.64925
```

——— 必要サンプルサイズ


```
sig.level = 0.025
```

```
power = 0.8
```

```
alternative = greater
```

必要サンプルサイズは31例

先週計算した数値結果ともほぼ一致
(近似計算をしている)



二群の平均の検定: 降圧薬

演習

標準治療での12週後のSBP低下は平均10 mmHg、新薬では15 mmHg低下が期待される(差=5 mmHg、SD=10 mmHgと仮定)。

等割付、片側検定、 $\alpha=0.025$ 、 $\beta=0.20$ で必要な症例数は何例か？

- 事前に設定するもの
 - 有意水準: 0.025, 目標検出力: 0.8
 - 12週後のSBP低下の分布についての仮定:
標準治療 $N(\mu_1, \sigma^2)$, 新薬 $N(\mu_2, \sigma^2)$, $\sigma=10$
 - 帰無仮説: $H_0: \mu_1 = \mu_2$, 対立仮説: $H_1: \mu_1 < \mu_2$
 - 検出したい最小の効果: $\mu_2 - \mu_1 = 5$

二群の平均の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.t.test()` 関数による計算
 - 二群の平均の差の検定の検出力計算、サンプルサイズ計算の関数

```
> d <- 5/10  
> pwr.t.test(d=d, sig.level = 0.025, power = 0.8, alternative = "greater")
```

効果の大きさ

有意水準

検出力

片側検定

Two-sample t test power calculation

```
n = 63.76561
```

```
d = 0.5
```

```
sig.level = 0.05
```

```
power = 0.8
```

```
alternative = two.sided
```

必要サンプルサイズ

NOTE: n is number in *each* group


参考：関数の中でやっていること

検定統計量: $Z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{2\sigma^2/n}} \sim N\left(\frac{\mu_1 - \mu_2}{\sqrt{2\sigma^2/n}}, 1\right)$

$\bar{x}_1$: 標準治療でのSBP低下の平均

 $\bar{x}_2$: 新薬でのSBP低下の平均

この式を満たすnを求める



数値の確認

- `pwr.t.test()` 関数による計算結果を用いて検出力を確認


```
> res_t <- pwr.t.test(d=d, sig.level = 0.025, power = 0.8, alternative = "greater")
> str(res_t)
List of 7
 $ n      : num 63.8 — 必要サンプルサイズ
 $ d      : num 0.5
 $ sig.level : num 0.025
 $ power   : num 0.8
 $ alternative: chr "greater"
 $ note    : chr "n is number in *each* group"
 $ method   : chr "Two-sample t test power calculation"
 - attr(*, "class")= chr "power.htest"
>
> print(res_t$n)
[1] 63.76576
> print(qnorm(0.975))
[1] 1.959964
>
> pnorm(qnorm(0.975), mean = 5/(sqrt(2*10^2/(res_t$n))), sd = 1, lower.tail = FALSE)
[1] 0.8060089 — 検出力
```

Δ
 $\sqrt{2\sigma^2/n}$

検出力曲線と必要サンプルサイズの視覚化

- `pwr.t.test()` 関数による結果は `plot()` 関数により `ggplot` オブジェクトとして扱える

```
> library(ggplot2)
> g <- plot(res_t, cex=2) +
+   theme_classic(base_size = 12)
>
> g
```



二群の割合の検定: 不眠症の治療薬

演習

既存の治療薬の成功率が30%であり、新しい治療薬で50%の成功率が見込まれる状況でRCTを実施するとして。

等割付、片側検定、 $\alpha=0.025$ 、 $\beta=0.20$ のもとで必要な症例数は何例か？

- 事前に設定するもの
 - 有意水準: 0.025, 目標検出力: 0.8
 - 治療成功の症例数の分布についての仮定:
既存治療 $B(n, p_1)$, 新治療 $B(n, p_2)$
 - 帰無仮説: $H_0: p_1 = p_2$, 対立仮説: $H_1: p_1 < p_2$
 - 検出したい最小の効果: $p_2 - p_1 = 0.5 - 0.3 = 0.2$

二群の割合の検定におけるサンプルサイズ計算

- `pwr` パッケージの `pwr.2p.test()` 関数による計算
 - 近似を用いた計算手法

```
> p1 <- 0.3
> p2 <- 0.5
> h <- ES.h(p2, p1)
> res_prop_test <- pwr.2p.test(h = h, sig.level = 0.025, power = 0.8, alternative = "greater")

> res_prop_test
```

効果の大きさの算出

効果の大きさ 有意水準 検出力 片側検定

Difference of proportion power calculation for binomial distribution (arcsine transformation)

```
      h = 0.4115168
      n = 92.69631
sig.level = 0.025
power = 0.8
alternative = greater
```

必要サンプルサイズ


NOTE: same sample sizes

検出力曲線と必要サンプルサイズの視覚化

- `pwr.2p.test()` 関数による結果は`plot()` 関数により ggplotオブジェクトとして扱える

```
library(ggplot2)
g <- plot(res_prop_test, cex=2) +
  theme_classic(base_size = 12)

g
```



候補サンプルサイズの検出力評価による設計

- 複雑な検定(中間解析、適応的デザイン)などを用いる場合
検出力を解析的に求めることが難しい場合がある
- 検出力は評価できるが、サンプルサイズを直接求めることが難しい場合がある

このような場合に以下のようなアプローチをとることがある

- 候補となるサンプルサイズを設定し、各候補における検出力を評価
(必要であればシミュレーションにより計算)
- 得られた検出力を目標値と比較し、必要サンプルサイズを決定

例：新規がん治療の臨床試験

第12回の演習で行った方法を1例ずつ変えて行う

演習：

以下の検定問題においてサンプルサイズを $n = 10, 20, \dots$ と変えていったとき、検出力がどのように変化するか観察してみよう

- $H_0: p_{\text{new}}=p_0$ vs $H_1: p_{\text{new}}>p_0$ (片側検定)
 - $p_0=0.4$ (帰無仮説の反応率)
 - $p_{\text{new}}=0.65$ (対立仮説の真の反応率)
- 有意水準 $\alpha=0.025$
- 検定統計量 $X(\sim \text{Binom}(n, p))$: 反応回数
- シミュレーション回数: 2000回

コード例：候補サンプルサイズの検出力評価

- この例では、検出力は理論的に求まるがシミュレーションを用いる場合のコードの流れも紹介する
- シミュレーションの設定

```
set.seed(123)                # 乱数シード固定
alpha      <- 0.025           # 有意水準（片側）
p0         <- 0.4             # 帰無仮説下の反応率
p_true     <- 0.65            # 真の反応率（> p0）
nsim       <- 2000            # シミュレーション回数
sample_sizes <- seq(20, 50, by = 1) # サンプルサイズの設定 1例ずつ
```

コード例：候補サンプルサイズの検出力評価

- シミュレーションの実行

```
sim_power      <- numeric(length(sample_sizes))
theory_power   <- numeric(length(sample_sizes))

for (i in seq_along(sample_sizes)) {
  n <- sample_sizes[i]

  ## ---- 片側棄却域（上側） -----
  # crit は  $P_{H_0}(X > \text{crit}) \leq \alpha$  を満たす最大の閾値
  # 棄却条件:  $X > \text{crit}$ 
  crit <- qbinom(1 - alpha, n, p0) # 小さいほうの分位点

  # シミュレーション検出力
  x_sim      <- rbinom(nsim, n, p_true)
  sim_power[i] <- mean(x_sim > crit)

  # 理論検出力
  theory_power[i] <- 1 - pbinom(crit, n, p_true)
}
```



コード例：候補サンプルサイズの検出力評価

- 検出力曲線の描画

```
df <- data.frame(  
  n = c(sample_sizes, sample_sizes),  
  power = c(sim_power, theory_power),  
  group = c(rep("simulation", length(sim_power)), rep("theory",  
length(theory_power)))  
)  
  
library(ggplot2)  
g <- ggplot(data = df, aes(x = n, y = power, group = group)) +  
  geom_line(aes(color = group)) +  
  geom_point(aes(color = group)) +  
  theme_bw(base_size = 18)  
print(g)
```

候補サンプルサイズの検出力評価による設計

- 検出力を満たす最小の n をサンプルサイズとする
- 今回のケースでは
検出力曲線が
単調増加でない
- 閾値を
 $P_{\{H_0\}}(X > \text{crit}) \leq \alpha$ を満たす
最大の閾値
として設定
- 離散変数なので
 α が有意水準から
大きく離れる場合がある



コード例: 第一種の過誤確率の評価

- 閾値に対応した第一種の過誤確率の計算の追加

```
sim_power      <- numeric(length(sample_sizes))
theory_power   <- numeric(length(sample_sizes))
theory_alpha   <- numeric(length(sample_sizes))

for (i in seq_along(sample_sizes)) {
  n <- sample_sizes[i]

  crit <- qbinom(1 - alpha, n, p0) # 小さいほうの分位点


  x_sim      <- rbinom(nsim, n, p_true)
  sim_power[i] <- mean(x_sim > crit)

  theory_power[i] <- 1 - pbinom(crit, n, p_true)

  # 第一種の過誤確率の実際の値
  theory_alpha[i] <- 1 - pbinom(crit, n, p0)
}
```


第一種の過誤確率と第二種の過誤確率の関係

- 第一種の過誤と第二種の過誤はトレードオフの関係
- 第一種の過誤が0.025より小さい
→ 第二種の過誤が大きくなる
= 検出力が小さくなる
- 検出力が設定を下回らない
最小のサンプルサイズ /
第一種の過誤が0.025に近く
検出力を達成する最小のサンプルサ



正確な確率による計算と近似による計算

- 新規がん治療の臨床試験の例
 - 近似による計算
 $n = 31$
 - 正確確率による計算
 $n = 32$
- 注意が必要
 - n が少ない時
 - 確率が0,1に近いとき
- 臨床試験においては脱落割合なども考慮される



提出課題

p. 18の演習において、以下の設定でp. 20のサンプルサイズ計算の結果の入った検出力曲線を描画し、画像ファイルとして保存したものを提出

- 既存の治療薬の成功率が40%
- 新しい治療薬で65%の成功率が見込まれる
- 残りの設定はp. 18と同様

提出方法: KULMSの課題提出機能

提出期限: 7/15(水)23:55

予告:コーディングテスト 7/21(火)13:20-

これまでの実習の習得度を評価するためにコーディングテストを実施します

- 提示された問題をRで実装・処理し、いつもの課題提出と同じ形式で提出する形式
- 実施時間は40分(13:20-14:00)
- 範囲:第7回から第13回までの内容
- 持ち込みは可, web検索および生成AIの利用は不可

補足: arcsine変換・Cohen's h

`pwr.2p.test()` 関数における近似

中心極限定理より二項分布 $B(n, p)$ に従う標本の平均の漸近分布は

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

- 割合 p が 0 または 1 に近づくと分散が小さくなる
→ 同じ割合の差でも精度が異なる
- $\theta = 2 \cdot \arcsin(\sqrt{p})$ とすると、 $\Delta\theta$ の分散はほぼ一定になる
($\arcsin$ は逆正弦関数)
→ θ の差を効果量として用いる (Cohen's h)

補足: 外部の症例数設計ツール

- Southwest Oncology Groupのデータセンターが提供

<https://stattools.crab.org/>

- G*Power

<https://www.psychologie.hhu.de/arbeitsgruppen/allgemeine-psychologie-und-arbeitspsychologie/gpower>



Design	Analysis
One Arm Binomial	Frequency Table
One Arm Binomial	Binomial Confidence Interval
One Arm Survival	
Two Stages	Binomial
Two Arm Binomial	Normal
Two Arm Binomial	Poisson
Two Arm Survival	Chi Square
Binomial Interaction	Probability of Observing a Rare Event
Survival Interaction	
Binomial Noninferiority	Prognostic Mixture
Survival Noninferiority	Survival Calculator
Expected Events (1 Arm)	
Continuous Marker Prognostic Power	

